Pranav Kasela 846965

```
library(ggplot2)
library(forecast)
library(tidyverse)
```

```
df <- read.csv2("time_series_dataset.csv", dec = ".")
df$Data <- as.Date(df$Data)
head(df)
```

```
##         Data     value
## 1 2010-01-01  41.65104
## 2 2010-01-02 131.28660
## 3 2010-01-03 117.38812
## 4 2010-01-04 116.46128
## 5 2010-01-05 123.82376
## 6 2010-01-06 104.28556
```

Arima Models

Splittiamo il dataset in train e test per verificare come va il modello su nuovi dati.

```
train <- df[1:(nrow(df) - 365),] #last one year is for validation
test  <- df[(nrow(df) - 365 + 1):nrow(df),]

ggplot(data=train, aes(x=Data, y=value)) +
  geom_line()
```

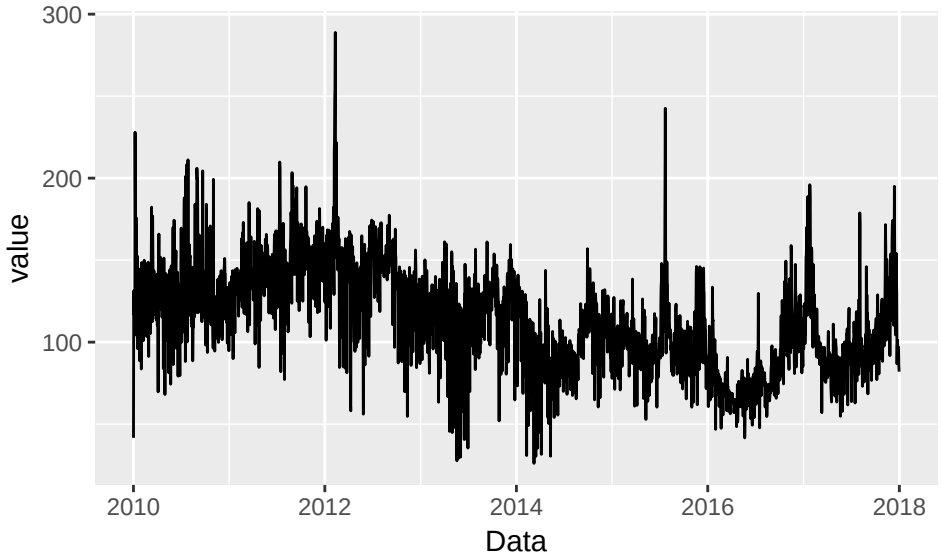


```
#This is the function ggtsdisplay of forecast package,
#but it has been modified so is doesn't plot the series,
#just the ACF and PACF plot, with the horizontal parameter
#the plot can be either horizontal or vertical
#The function has been simplified a lot, since we don't need
#all the complexity the original one has.
```

```r
ggtsdisplay_2 <- function(x, lag.max, horizontal=TRUE, ...) {
    if (!is.ts(x)) {
      x <- ts(x)
    }
    if (missing(lag.max)) {
      lag.max <- round(min(max(10 * log10(length(x)), 3 * frequency(x)), length(x) / 3))
    }
    ######      END   CHECKING    ########

    # Set up grid for plots
    if (horizontal){
      gridlayout <- matrix(c(2, 3), nrow = 1)
    }
    else{
      gridlayout <- matrix(c(2, 3), nrow = 2)
    }
    grid::grid.newpage()
    grid::pushViewport(grid::viewport(layout = grid::grid.layout(nrow(gridlayout), ncol(gridlayout))))

    # Prepare Acf plot
    acfplot <- do.call(ggAcf, c(x = quote(x), lag.max = lag.max)) +
      ggplot2::ggtitle("ACF") + ggplot2::ylab(NULL)

    # Prepare last plot (variable)
    pacfplot <- ggPacf(x, lag.max = lag.max) + ggplot2::ggtitle("PACF") +
      ggplot2::ylab(NULL)
    # Match y-axis
    acfplotrange <- ggplot2::layer_scales(acfplot)$y$range$range
    pacfplotrange <- ggplot2::layer_scales(pacfplot)$y$range$range
    yrange <- range(c(acfplotrange, pacfplotrange))
    acfplot <- acfplot + ggplot2::ylim(yrange)
    pacfplot <- pacfplot + ggplot2::ylim(yrange)

    # Add ACF plot
    matchidx <- as.data.frame(which(gridlayout == 2, arr.ind = TRUE))
    print(
      acfplot,
      vp = grid::viewport(
        layout.pos.row = matchidx$row,
        layout.pos.col = matchidx$col
      )
    )

    # Add PACF plot
    matchidx <- as.data.frame(which(gridlayout == 3, arr.ind = TRUE))
    print(
      pacfplot,
      vp = grid::viewport(
        layout.pos.row = matchidx$row,
        layout.pos.col = matchidx$col
      )
    )
```

```
}

ggtsdisplay_2(train$value, horizontal = TRUE, lag.max = 60)
```

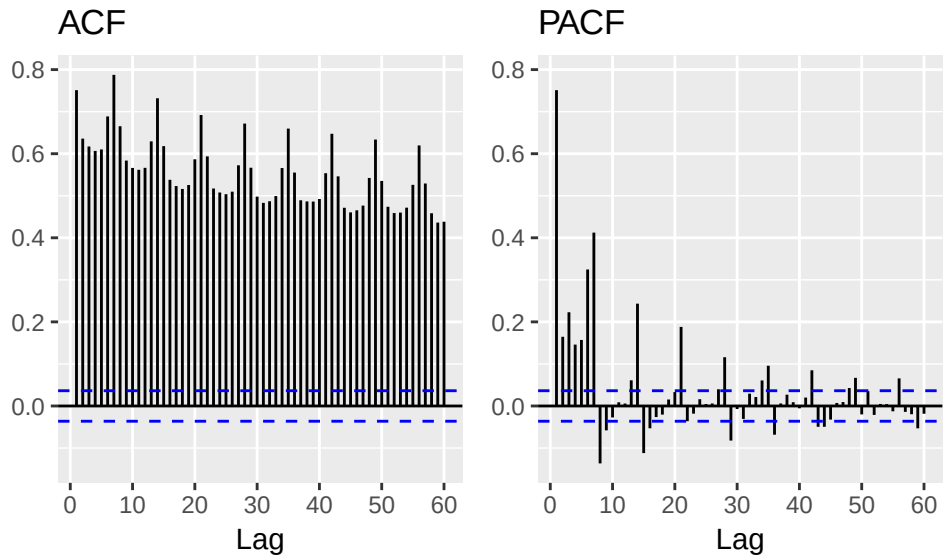

Possiamo vedere che nel PACF vi sono 7 ritardi e il ritrado stagionale che scende esponenzialemente al settimo ritardo, indicando la presenza di un $\text{SMA}(1)_7$ e vedendo ACF dai primi 2 ritardi stagionali ci convinciamo dell'esistenza di $\text{SMA}(1)_7$, inoltre vi è presente anche un $\text{SAR}(1)_7$. Stagionalità 7 indica un periodo settimanale in questa serie. Inoltre vista la discesa lenta e non geometrica della ACF potrebbe suggerire l'esistenza di una integrazione stagionale. Iniziamo ad aggiungere la parte stagionale prima e cerchiamo di capire dai residui come andrebbe aggiustato il modello.

```
mod1 <- Arima(train$value, c(0,0,0), list(order=c(1,0,1), period=7), lambda = "auto")
ggtsdisplay_2(mod1$residuals)
```

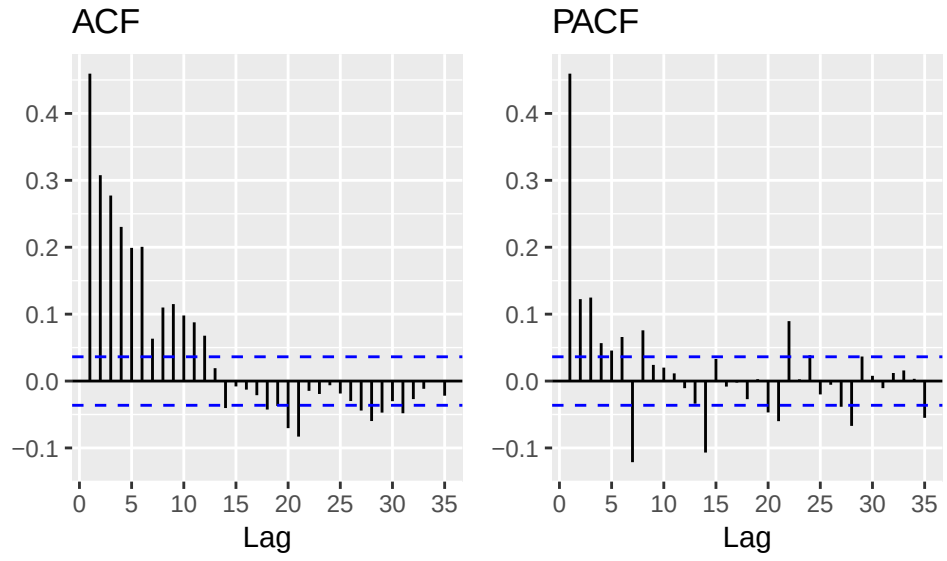


```
mod1
```

```
## Series: train$value
## ARIMA(0,0,0)(1,0,1)[7] with non-zero mean
```

```
## Box Cox transformation: lambda= 0.9437982
##
## Coefficients:
##         sar1     sma1     mean
##       0.9591  -0.5557  92.6251
## s.e.  0.0063   0.0229   2.5938
##
## sigma^2 estimated as 183.9:  log likelihood=-11767.49
## AIC=23542.97   AICc=23542.98   BIC=23566.89
```

Vediamo anche che il coefficiente di SAR è molto vicino ad 1, quindi ha radice unitaria e ciò dice che esiste l'integrazione stagionale che sospettavamo prima.

```
mod2 <- Arima(train$value, c(6,0,0), list(order=c(1,1,1), period=7), lambda = "auto")
ggtsdisplay_2(mod2$residuals, lag.max = 400)
```

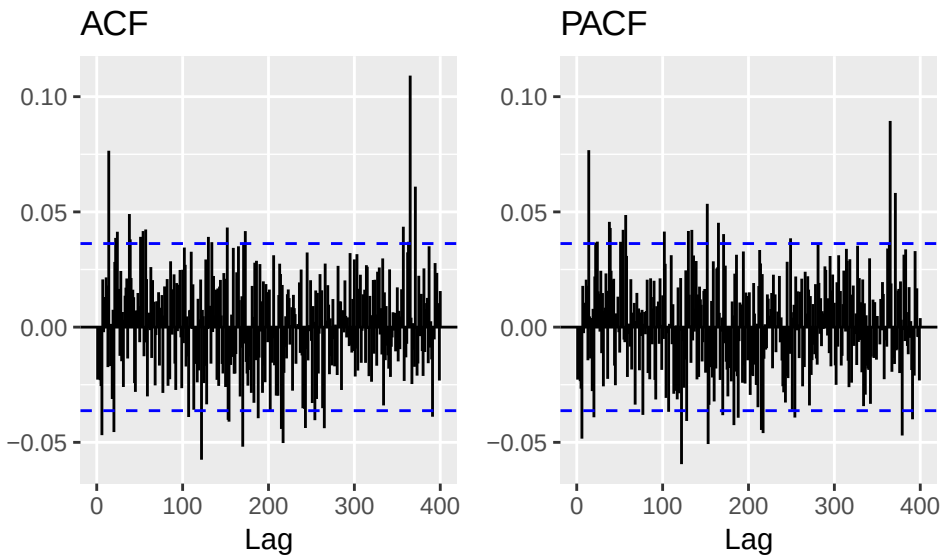

I residui sembrano essere rientrati nella banda tranne un residuo a 14 sia un ACF che PACF.

Usiamo il test Augmented Dickey-Fuller, che cerca radici unitarie nella serie, per verificare se la serie è stazionaria, con k che indica il ritardo autoregressivo, H_0 è la presenza di radici unitarie nella serie, H_1 è che la serie è stazionaria.

```
#Trying Augmeted Dickey-Fuller test to see if the series is stationary:
#$H_0$ is that the model is not stationary
tseries::adf.test(mod2$residuals, k=6)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  mod2$residuals
## Dickey-Fuller = -21.664, Lag order = 6, p-value = 0.01
## alternative hypothesis: stationary
```

Poiché il p-value è basso rifiutiamo l'H_0 e possiamo dire che i residui della sono stazionari. Questo è per il modello AR, mentre per SAR lo abbiamo già visto prima.

```
plot(forecast(mod2, h=365), include = 1000)
lines(df$value, col="black")
```

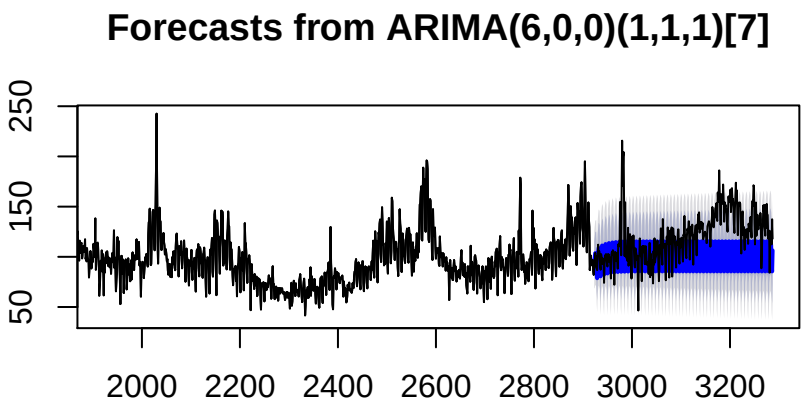

Mettiamo regressori dummy mensili e ogni 4 settimane.

```
#create dummy
data.frame(Data=df$Data) %>%
  mutate(M = months(Data), ind = 1) %>%
  spread(M, ind, fill = 0) %>%
  mutate(W = paste0("W",(data.table::week(Data) %% 4 + 1)), ind=1) %>%
  spread(W, ind, fill = 0) %>%
  select(-starts_with("Data")) %>% as.matrix() -> more_reg

#eliminiamo la prima e l'ultima colonna, per evitare multicollinearità
xreg <- more_reg[,2:(ncol(more_reg)-1)]

mod1_reg <- Arima(train$value, c(6,0,0), list(order=c(1,1,1), period=7),
              xreg=xreg[1:(nrow(df)-365),], include.constant = TRUE, lambda = "auto")
ggtsdisplay_2(mod1_reg$residuals, lag.max = 400)
```

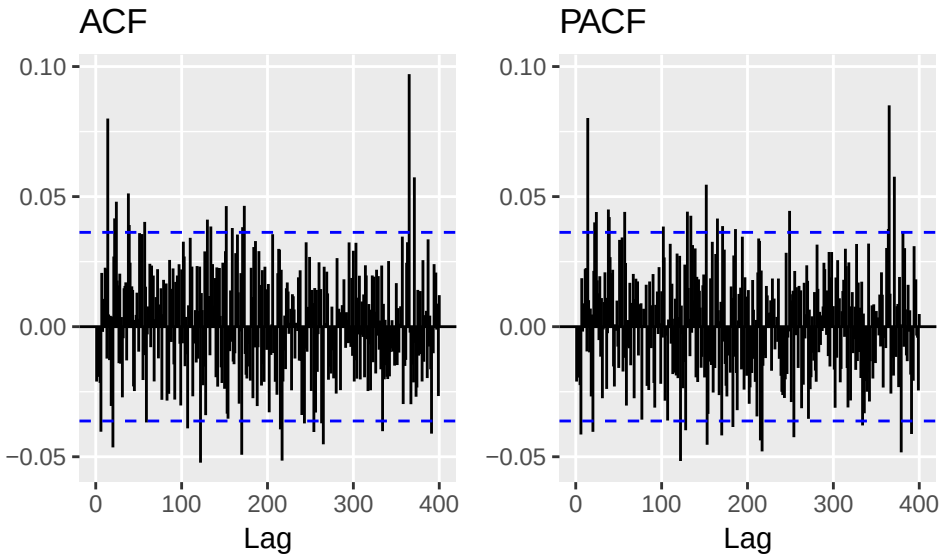

```
plot(forecast(mod1_reg, h=365,
              xreg=xreg[(nrow(df)-365+1):nrow(df),]),
     include = 1000)
lines(forecast(mod2, h=365)$mean,col="red")
lines(df$value, col="black")
```

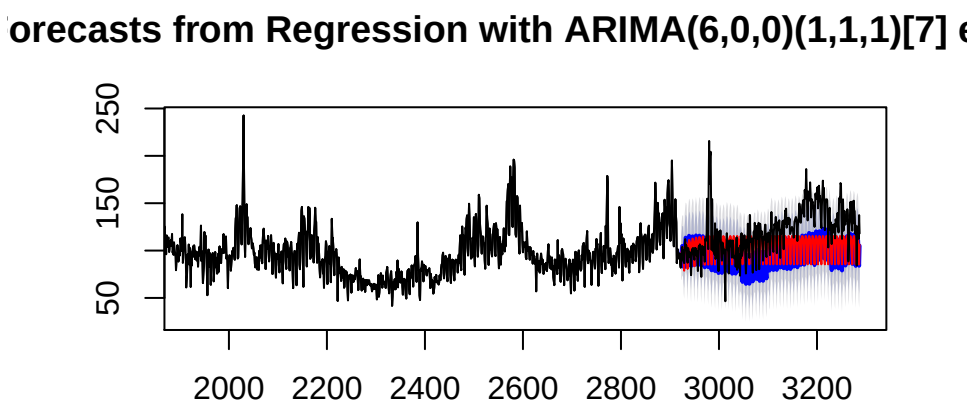

Questa serie presenta in realtà una multi-stagionalità, che non può essere risolta con R, per questo si prova ad usare regressori esterni, introducendo una stagionalità annuale e ogni 4 settimane.

```
mod_reg_y <- forecast(mod1_reg, h=365,
                      xreg=xreg[(nrow(df)-365+1):nrow(df),])$mean
mod2_y <- forecast(mod2, h=365)$mean

mse_reg <- sqrt(((mean((test$value - mod_reg_y)/test$value))^2))
mse_2   <- sqrt(((mean((test$value - mod2_y)/test$value))^2))

print(paste0("MSE relativo modello senza regressori : ", mse_2))
```

```
## [1] "MSE relativo modello senza regressori : 0.100177354498053"
```

```
print(paste0("MSE relativo modello con regressori : ", mse_reg))
```

```
## [1] "MSE relativo modello con regressori : 0.144119110733352"
```

In realtà si nota che il modello performa peggio sul validation se vengono fornite regressori esterni per indicare il mese e la settimana, ciò è dovuto al fatto che nell'ultimo anno l'andamento è diverso dagli ultimi anni, oppure queste variabili non sono tanto esplicative quanto si credeva e aggiungono solo del rumore alla previsione.

UCM

```
library(KFAS)
library(xts)
```

```
#y <- xts(df$value, df$Data)
#ytrain <- y["2010-01-01/2017-12-31"]
```

```r
#plot(ytrain)
ytrain <- train$value
ytrain[length(ytrain):(length(ytrain)+365)] <- NA
```

```r
mod1 <- SSModel(ytrain ~ 0 +
                  SSMtrend(1, NA) +
                  SSMseasonal(7, NA, "dummy") +
                  SSMseasonal(365, 0, "trig",
                              harmonics = 1:12),
                H = NA)

vary <- var(ytrain, na.rm = TRUE)
mod1$P1inf <- mod1$P1inf * 0
mod1$a1[1] <- mean(ytrain, na.rm = TRUE)
diag(mod1$P1) <- vary

# Initial values for the variances we have to estimate
init <- numeric(3)
init[1] <- log(vary/10) # log-var(dist.rw)
init[2] <- log(vary/100)# log-var(dist.seas)
init[3] <- log(vary/10) # log-var(err.oss.)

# Estimate
fit1 <- fitSSM(mod1, init)
fit1$optim.out$convergence
```

```
## [1] 0
```

```r
smo1 <- KFS(fit1$model, smoothing = c("state", "disturbance", "signal"))
smo1_seas <- rowSums(smo1$alphahat[1:(length(ytrain) -365), seq(8, 27, 2)])

plot(ytrain[1:(length(ytrain) -365)], type = "l")
lines(smo1$alphahat[1:(length(ytrain) -365), "level"], col = "red")
lines(smo1$alphahat[1:(length(ytrain) -365), "level"] +
        smo1_seas[1:(length(ytrain) -365)], col = "blue")
lines(smo1$alphahat[1:(length(ytrain) -365), "level"] +
        smo1$alphahat[1:(length(ytrain) -365), "sea_dummy1"] +
        smo1_seas[1:(length(ytrain) -365)], col = "green")
```

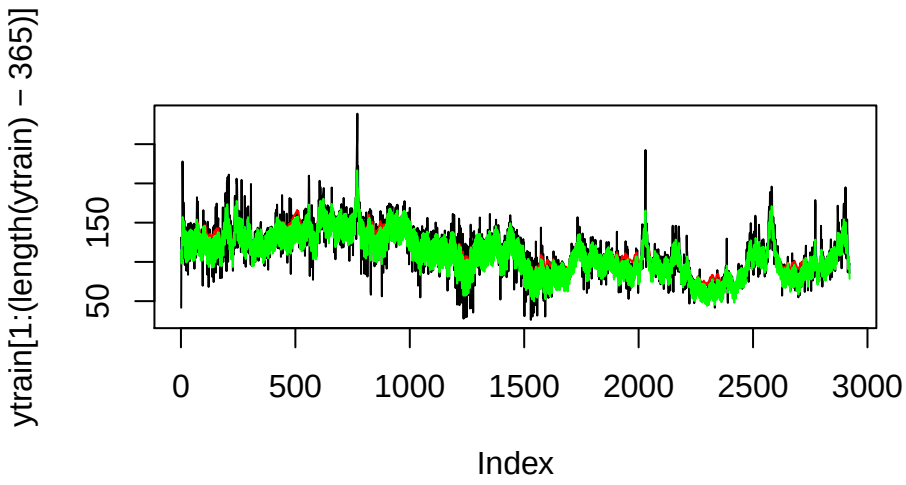


```
smo1 <- KFS(fit1$model, smoothing = c("state","disturbance","signal"))


xarima_pred <- as.numeric(forecast(mod1_reg, h=365,
                 xreg=xreg[(nrow(df)-365+1):nrow(df),])$mean)

arima_pred  <- as.numeric(forecast(mod2, h=365)$mean)


test %>%
  mutate(UCM = smo1$muhat[(nrow(df)-365 +1):nrow(df)],
         XARIMA = xarima_pred, ARIMA = arima_pred) %>%
  ggplot(aes(x=Data)) +
  geom_line(aes(y=value, col="Real")) +
  geom_line(aes(y=UCM, col="UCM")) +
  geom_line(aes(y=ARIMA, col="ARIMA"), linetype="F1") +
  geom_line(aes(y=XARIMA, col="XARIMA")) +
  scale_color_manual(values= c("Real"="black",
                               "UCM"="darkred",
                               "ARIMA"="blue",
                               "XARIMA"="green")) +
  theme_bw()
```

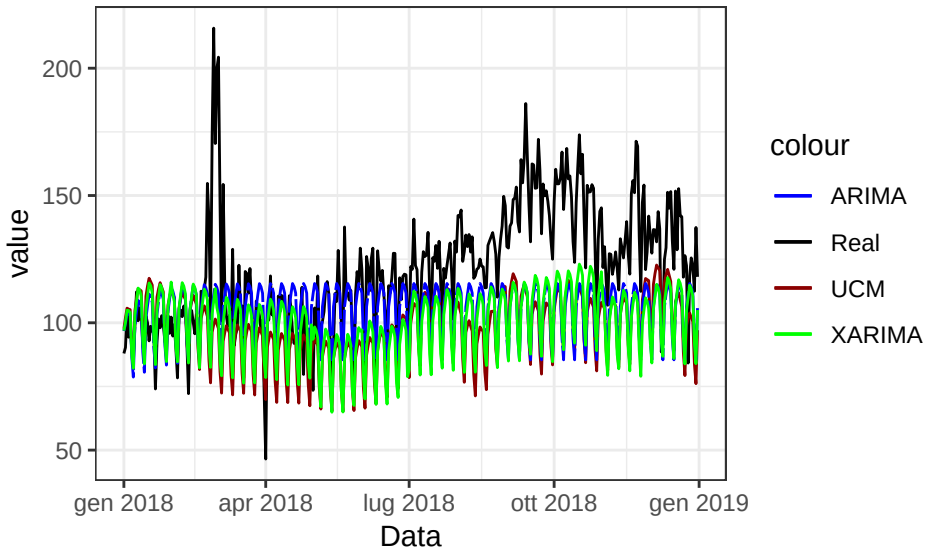


```
mse_ucm   <- sqrt(((mean((test$value - smo1$muhat[(nrow(df)-365 +1):nrow(df)])/test$value))^2))

print(paste0("MSE relativo modello ARIMA : ", mse_2))
```

```
## [1] "MSE relativo modello ARIMA : 0.100177354498053"
```

```
print(paste0("MSE relativo modello XARIMA : ", mse_reg))
```

```
## [1] "MSE relativo modello XARIMA : 0.144119110733352"
```

```
print(paste0("MSE relativo modello UCM : ", mse_ucm))
```

```
## [1] "MSE relativo modello UCM : 0.166231506965691"
```